Tuyển chọn các bộ dữ liệu và phân tích đặc trưng để phát hiện email lừa đảo bằng học máy

Tên gốc: Curated Datasets and Feature Analysis for Phishing Email Detection with Machine Learning

Tác giả: Arifa I. Champa, Md Fazle Rabbi, Minhaz F. Zibran.

Đơn vị: Khoa Khoa học Máy tính, Đại học Bang Idaho, Pocatello, Idaho, Hoa Kỳ. Email: {arifaislamchampa, mdfazlerabbi, minhazzibran}@isu.edu.

Công bố: Hội nghị quốc tế IEEE lần thứ 3 về Điện toán và Trí tuệ Máy, ICMI 2024. DOI: https://doi.org/10.1109/ICMI60790.2024.10585821.

Phạm vi bản dịch: Dịch đầy đủ nội dung khoa học của bản PDF 7 trang được cung cấp trong dự án: tóm tắt, các mục I–VII, 4 bảng, 3 hình cùng chú thích và 45 tài liệu tham khảo. Hình giữ nguyên đồ thị gốc; chú thích và giải thích nhãn được dịch bên dưới. Tên tài liệu tham khảo được giữ nguyên để tra cứu. Đây là bài báo làm cơ sở dữ liệu và thực nghiệm phân loại **email** của DT124; bài báo nền tảng về **tên miền phishing** được dịch trong một tệp riêng. Các nhận định, số liệu và giới hạn bên dưới là của bài báo gốc, không phải kết quả M0/M1/M2 do dự án DT124 thực hiện.

Quy ước: *Phishing email* được dịch là "email lừa đảo"; *legitimate email* là "email hợp lệ"; *curation* là quá trình tuyển chọn và chuẩn bị dữ liệu. Tên trường `Sender`, `Receiver`, `Date`, `Subject`, `Body`, `Urls` được giữ để đối chiếu. Trong nguồn dữ liệu, nhãn dương có thể bao gồm thư rác thông thường; bản dịch giữ cách gọi phishing/scam của tác giả, không tự nâng ý nghĩa nhãn lên thành các cuộc tấn công phishing đã được xác minh.

Lưu ý đối chiếu: Một số số liệu Bảng III không khớp trực tiếp với Bảng II, và các bước xử lý ở Bảng I không luôn tạo thành một phép kiểm kê khép kín. Bản dịch giữ nguyên các giá trị đã in; ghi chú biên dịch được tách riêng ở cuối để tránh sửa dữ liệu của tác giả.

Tóm tắt

Mặc dù hoạt động nghiên cứu vẫn được tiếp tục, các cuộc tấn công bằng email lừa đảo đang gia tăng, trong khi còn thiếu những bộ dữ liệu phong phú đã được tuyển chọn để huấn luyện và kiểm thử các kỹ thuật lọc email. Để giải quyết vấn đề này, chúng tôi tạo và công bố bảy bộ dữ liệu đã tuyển chọn, gồm 203.176 mẫu email, phục vụ việc dùng học máy (ML) để phân biệt email lừa đảo với email hợp lệ. Chúng tôi xây dựng các bộ dữ liệu này bằng cách tuyển chọn cẩn thận email lừa đảo và email hợp lệ từ nhiều kho khác nhau. Sau đó, để chứng minh các bộ dữ liệu phù hợp với mục đích này, chúng tôi tiến hành phân tích định lượng nhằm đánh giá hiệu năng của năm thuật toán ML. Chúng tôi cũng phân tích ý nghĩa và tác động của các đặc trưng khác nhau trong những bộ dữ liệu đã tuyển chọn đối với các thuật toán ML đó. Những bộ dữ liệu này, cùng các kết quả phân tích định lượng, sẽ thúc đẩy việc phát triển biện pháp phòng vệ vững chắc trước các cuộc tấn công phishing.

Từ khóa: Email lừa đảo, tuyển chọn dữ liệu, xử lý ngôn ngữ tự nhiên, học máy, phân tích định lượng, phát hiện.

I. Giới thiệu

Trong nhiều thập kỷ, giao tiếp qua email đã trở thành một phần không thể thiếu của đời sống nghề nghiệp và cá nhân. Tuy nhiên, điều này cũng khiến email trở thành mục tiêu hàng đầu của các cuộc tấn công phishing, gây ra những rủi ro an ninh đáng kể. Trong các cuộc tấn công bằng email lừa đảo, tội phạm mạng tạo ra những email đánh lừa người nhận, giả dạng thư trao đổi hợp lệ để dụ người dùng mất cảnh giác tiết lộ thông tin nhạy cảm. Những thủ đoạn này có thể dẫn đến rò rỉ dữ liệu và nhiều hoạt động độc hại khác. Đáng chú ý, không chỉ những người dùng thông thường dễ bị mắc bẫy; ngay cả những người có trình độ học vấn cao cũng có thể trở thành nạn nhân [1]. Theo ước tính được bài báo dẫn lại, khoảng 91% các nỗ lực xâm nhập bắt đầu từ một email phishing [2], và có tới 3,4 tỷ email phishing được gửi mỗi ngày [3].

Bài báo này giải quyết mối lo ngại ngày càng lớn về các cuộc tấn công phishing, vốn đang trở nên thường xuyên và tinh vi hơn. Chỉ riêng năm 2023 đã có gần 6 tỷ vụ xâm phạm an ninh, trong khi các cuộc tấn công phishing xảy ra với tần suất xấp xỉ một vụ mỗi 11 giây [3]. Bất chấp tiến bộ công nghệ, phishing vẫn là mối đe dọa lớn, khi tội phạm mạng liên tục nghĩ ra những trò lừa đảo mới. Chẳng hạn, bộ lọc Gmail chặn hàng triệu email phishing, trong đó một phần đáng kể là các hình thức lừa đảo mới chưa từng gặp trước đó [4]. Những thống kê đáng báo động này nhấn mạnh nhu cầu cấp thiết về các phương pháp phát hiện phishing hiệu quả và vững chắc hơn.

Trước nhu cầu quan trọng này, các cuộc tấn công phishing đã trở thành chủ đề của nhiều nghiên cứu sâu rộng [5]–[8]. Một thách thức đáng kể của lĩnh vực là sự khan hiếm các bộ dữ liệu thực tế, đa dạng, phong phú và được tuyển chọn tốt [9]. Điều này thúc đẩy chúng tôi xem xét kỹ mức độ phù hợp của những kho/bộ dữ liệu email có tiềm năng phục vụ phát hiện email phishing. Qua khảo sát, chúng tôi nhận thấy các kho/bộ dữ liệu email hiện có tuy có giá trị nhưng chưa thể sử dụng ngay vì nhiều lý do. Một số kho chứa email thô cần được tuyển chọn trước khi đưa vào thuật toán ML. Một số email được mã hóa cần được giải mã trước; một số ở định dạng HTML cần được trích xuất nội dung văn bản thuần; một số email được viết bằng ngôn ngữ khác tiếng Anh, trong khi một số có phần thân rỗng, nên phải lọc trước khi áp dụng ML. Trên hết, việc tuyển chọn kết hợp trích xuất các đặc trưng như URL là cần thiết để dữ liệu sẵn sàng cho các thuật toán ML.

Vì vậy, chúng tôi tạo và công bố công khai bảy bộ dữ liệu email phishing đã được tuyển chọn tỉ mỉ để có thể áp dụng ML ngay. Các bộ dữ liệu này bao gồm những mẫu email lừa đảo và email hợp lệ đại diện cho email thực tế, từ giao tiếp cá nhân đến giao tiếp doanh nghiệp ở nhiều giai đoạn lịch sử. Chúng tôi cũng nhận thấy rằng, để triển khai và áp dụng các giải pháp phát hiện email phishing dựa trên ML trong thực tế, điều hết sức quan trọng là xác định các đặc điểm và thuộc tính của giao tiếp email đóng góp nhiều nhất vào việc phân biệt email lừa đảo với email hợp lệ. Do đó, chúng tôi áp dụng năm thuật toán ML phổ biến lên các bộ dữ liệu: thứ nhất, để kiểm tra và chứng minh dữ liệu đã tuyển chọn phù hợp với ứng dụng ML; thứ hai, để xác định những đặc trưng email có ảnh hưởng lớn nhất đến việc các thuật toán phân loại email phishing và không phishing.

Những đóng góp chính: Để trình bày rõ ràng và cụ thể, chúng tôi nhắc lại hai đóng góp chính của công trình như sau.

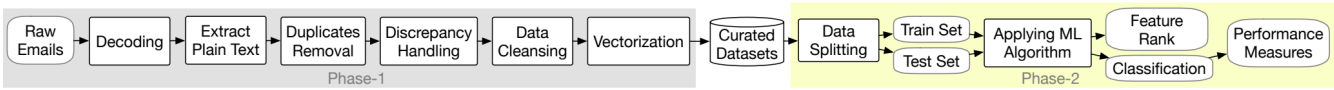
- Chúng tôi công bố một tập hợp gồm bảy bộ dữ liệu [10], [11], mỗi bộ chứa các email lừa đảo và hợp lệ được tuyển chọn kỹ, sẵn sàng để áp dụng trực tiếp các thuật toán ML hoặc thực hiện những phân tích tương tự. Bản gốc mô tả đóng góp này bằng cụm “balanced collection”; phần III đồng thời trình bày cả các bộ dữ liệu cân bằng và mất cân bằng.

• Bằng cách áp dụng năm thuật toán ML phổ biến lên các bộ dữ liệu, chúng tôi chứng minh mức độ phù hợp và sẵn sàng của dữ liệu cho ML, đồng thời rút ra hiểu biết về tác động của các đặc trưng email lên quá trình ra quyết định của thuật toán. Những hiểu biết này cần thiết cho việc phát triển các phương pháp tinh vi và có mục tiêu phù hợp.

Phần còn lại của bài báo được tổ chức như sau. Mục II mô tả phương pháp tuyển chọn và tạo bảy bộ dữ liệu. Mục III trình bày các bộ dữ liệu thu được. Mục IV trình bày phân tích định lượng, trong đó năm thuật toán ML được áp dụng để chứng minh tính phù hợp của dữ liệu và khảo sát độ quan trọng của đặc trưng. Mục V đề cập các giới hạn của nghiên cứu và những nỗ lực nhằm giảm thiểu chúng. Mục VI thảo luận các công trình liên quan. Cuối cùng, Mục VII kết luận và nêu một số hướng nghiên cứu tiếp theo.

II. Tuyển chọn và tạo các bộ dữ liệu

Như Hình 1 thể hiện, công việc được tiến hành qua hai giai đoạn. Trong giai đoạn 1, chúng tôi xử lý và tuyển chọn các tập email để tạo ra bảy bộ dữ liệu. Trong giai đoạn 2, chúng tôi áp dụng năm thuật toán ML lên các bộ dữ liệu để chứng minh tính phù hợp và rút ra hiểu biết về độ quan trọng của đặc trưng. Các bước trong mỗi giai đoạn được tóm tắt trong Hình 1 và được mô tả ở Mục II-B và Mục IV.



Hình 1. Các bước trong những giai đoạn khác nhau của công trình.

Dịch nhãn trong hình: Giai đoạn 1: email thô → giải mã → trích xuất văn bản thuần → loại bỏ trùng lặp → xử lý sai lệch → làm sạch dữ liệu → véc-tơ hóa → các bộ dữ liệu đã tuyển chọn. Giai đoạn 2: chia dữ liệu → tập huấn luyện/tập kiểm thử → áp dụng thuật toán ML → phân loại → các thước đo hiệu năng và xếp hạng đặc trưng.

A. Nguồn các tập email

Như đã đề cập, chúng tôi thu thập email từ nhiều nguồn. Kho Ling-Spam (Ling) [12] gồm các email từ năm 2000, đại diện cho giao tiếp email giai đoạn đầu. Những email này chủ yếu tập trung vào các chủ đề mà giới ngôn ngữ học quan tâm. Kho Enron [13] chứa các email có niên đại được bài báo mô tả là năm 2006. Kho Apache SpamAssassin (Assassin) [14] gồm email trải dài nhiều năm, từ 2002 đến 2006. Các kho công khai TREC được phát hành định kỳ vào các năm 2005 (TREC-05) [15], 2006 (TREC-06) [16] và 2007 (TREC-07) [17], bao gồm nhiều kiểu giao tiếp email trong ba năm liên tiếp. Kho đánh giá của CEAS 2008 Challenge Lab (CEAS-08) [18] chứa email có niên đại năm 2008.

B. Xử lý phục vụ tuyển chọn

Mặc dù email trong tất cả các nguồn nói trên đã được phân thành phishing hoặc hợp lệ, phần lớn dữ liệu còn ở dạng thô và cần được xử lý ở các mức độ khác nhau để sẵn sàng cho ML. Vì vậy, chúng tôi tiếp tục xử lý và tuyển chọn chúng để tạo các bộ dữ liệu. Những hoạt động này được tóm tắt ở giai đoạn 1 của Hình 1 và trình bày chi tiết dưới đây.

1) Giải mã: Các kho, ngoại trừ Ling, đều chứa email được mã hóa và cần giải mã trước. Để giải mã, trước tiên chúng tôi phân tích nội dung thô để xác định kiểu mã hóa được chỉ định trong phần header. Sau đó, chúng tôi áp dụng các kỹ thuật giải mã khác nhau tương ứng với từng loại dữ liệu đã mã hóa. Chẳng hạn, giải mã dữ liệu Base64 là thực hiện ngược lại quá trình mã hóa Base64. Tiếp theo, chúng tôi xử lý các bộ ký tự khác nhau theo chỉ dẫn của header `Content-Type`, bảo đảm chuỗi byte đã giải mã được chuyển chính xác thành chuỗi có thể đọc. Phương pháp tổng thể này đưa các phần đã mã hóa của email trở lại định dạng gốc dễ hiểu, điều quan trọng đối với việc tích hợp và phân tích xuyên suốt nghiên cứu. Chúng tôi sử dụng thư viện `email` của Python [19] để hỗ trợ giải mã email.

2) Trích xuất văn bản thuần: Chúng tôi quan sát thấy trong tất cả các kho, trừ Ling, có cả email định dạng HTML và email văn bản thuần. Để duy trì tính nhất quán và bảo đảm dữ liệu có thể đưa vào thuật toán ML, chúng tôi trích xuất văn bản thuần từ các email HTML. Ban đầu, chúng tôi giữ lại nội dung nằm trong một số thẻ định dạng, chẳng hạn `<strong>` và `<p>`, chỉ loại bỏ bản thân thẻ để giữ thông tin thiết yếu mà không giữ định dạng hiển thị. Sau đó, chúng tôi thay các dấu xuống dòng liên tiếp bằng một dấu cách, giúp máy dễ đọc hơn bằng cách bỏ những ngắt dòng không cần thiết. Văn bản thuần thu được cho phép xử lý dữ liệu đơn giản và nhất quán hơn, tạo nền tảng vững chắc cho các giai đoạn tiếp theo.

3) Loại bỏ trùng lặp: Để phát hiện email trùng lặp, chúng tôi phân tích nội dung trường `Body`, là phần cốt lõi của email. Nếu hai email có nội dung `Body` giống hệt nhau, chúng được coi là trùng lặp. Sau đó, chúng tôi loại bỏ email dư thừa và chỉ giữ lại một mẫu trong mỗi nhóm trùng lặp.

4) Xử lý sai lệch: Trong các kho đã chọn, chúng tôi nhận thấy một số email có phần thân rỗng. Những email này được loại khỏi nghiên cứu. Ngoài ra, chúng tôi chỉ giữ lại email viết bằng tiếng Anh để duy trì tính nhất quán.

5) Làm sạch dữ liệu: Để nâng cao tính toàn vẹn và chất lượng dữ liệu, chúng tôi làm sạch dữ liệu. Quá trình này bao gồm việc loại bỏ các từ dừng, chẳng hạn `and`, `the` và `is`, khỏi từng email. Bước này quan trọng vì giúp giảm nhiễu trong bộ dữ liệu.

6) Véc-tơ hóa: Dữ liệu email phải được chuyển thành các biểu diễn véc-tơ số để đưa vào thuật toán ML. Chúng tôi sử dụng kỹ thuật tần suất từ–nghịch đảo tần suất tài liệu (TF-IDF) trong xử lý ngôn ngữ tự nhiên (NLP), một phương pháp thống kê được sử dụng rất rộng rãi [20]–[22]. Phương pháp nhân tần suất từ (TF) của một từ với nghịch đảo tần suất tài liệu (IDF) của từ đó. TF biểu thị số lần từ xuất hiện trong một tài liệu cụ thể, còn IDF biểu thị mức độ phổ biến của từ trong toàn bộ tập tài liệu. Thuộc tính `Urls` được chuyển thành đặc trưng nhị phân: giá trị 1 cho biết phần thân email có URL; giá trị 0 cho biết không có URL.

III. Các bộ dữ liệu đã tuyển chọn thu được

Sau khi hoàn thành quá trình tuyển chọn như trên, chúng tôi thu được các bộ dữ liệu tương ứng với bảy kho gốc; mỗi bộ được đặt tên theo kho mà nó bắt nguồn. Bảng I tóm tắt bảy bộ dữ liệu do chúng tôi tạo ra. Hàng đầu tiên xác định tên từng bộ dữ liệu. Ở mỗi bộ, các hàng thứ hai, thứ ba và thứ tư tính từ trên lần lượt cho biết số mẫu email được xử lý ở các bước giải mã, loại bỏ trùng lặp và xử lý sai lệch. Các hàng còn lại cung cấp tổng quan về bộ dữ liệu sau khi tuyển chọn: tổng số email, số email hợp lệ, số email scam/phishing, tỷ lệ email hợp lệ so với email scam (Legit:Scam), và các đặc trưng có trong bộ dữ liệu.

Chẳng hạn, sau bước giải mã bộ Enron, chúng tôi có 30.494 email; loại bỏ 724 email trùng lặp; xử lý sai lệch ở ba email còn lại và thu được tổng cộng 29.767 email đã tuyển chọn. Trong đó, 15.791 email là hợp lệ và

13.976 email là phishing, cho tỷ lệ hợp lệ:lừa đảo bằng 53:47. Như hàng cuối của bảng thể hiện, Enron chỉ có hai đặc trưng email: `Subject` và `Body`. Chỉ hai bộ Ling và Enron có hai đặc trưng này; những bộ khác có sáu đặc trưng: `Sender`, `Receiver`, `Date`, `Subject`, `Body` và `Urls`.

Bảng I. Tóm tắt các bộ dữ liệu đã tuyển chọn được tạo và công bố.

Thuộc tính	Ling	Enron	Assassin	TREC-05	TREC-06	TREC-07	CEAS-08
Được giải mã	0	30.494	6.047	92.188	37.786	75.417	137.701
Trùng lặp	34	724	220	29.500	20.079	19.026	70.100
Sai lệch	0	3	18	3.413	254	3	1.217
Tổng số	2.859	29.767	5.809	55.414	16.416	53.757	39.154
Hợp lệ	2.401	15.791	4.091	32.329	12.411	24.358	17.312
Lừa đảo	458	13.976	1.718	23.085	4.005	29.399	21.842
Hợp lệ:Lừa đảo	84:16	53:47	70:30	58:42	76:24	45:55	44:56
Đặc trưng	Subject, Body	Subject, Body	Sender, Receiver, Date, Subject, Body, Urls	Sender, Receiver, Date, Subject, Body, Urls	Sender, Receiver, Date, Subject, Body, Urls	Sender, Receiver, Date, Subject, Body, Urls	Sender, Receiver, Date, Subject, Body, Urls

Như Bảng I cho thấy, quá trình tuyển chọn TREC-05, TREC-06, TREC-07 và CEAS-08 loại bỏ một lượng lớn email trùng lặp. Bước xử lý sai lệch cũng tác động đáng kể tới TREC-05, tiếp theo là CEAS-08, góp phần làm giảm mạnh số mẫu email. Tuy nhiên, việc loại bỏ những dữ liệu không nhất quán này là cần thiết để tăng độ vững chắc của thuật toán ML. Sau khi hoàn tất tuyển chọn, TREC-05 và TREC-07 có hơn 50 nghìn email mỗi bộ, trong khi CEAS-08 và Enron lần lượt có gần 40 nghìn và 30 nghìn email.

Các bộ Enron, TREC-07 và CEAS-08 tương đối cân bằng về tỷ lệ email phishing và email hợp lệ. Ngược lại, Ling mất cân bằng nhất, với tỷ lệ hợp lệ:lừa đảo bằng 84:16. TREC-06 và Assassin cũng có vẻ mất cân bằng. Mặc dù thuật toán ML nhìn chung hoạt động tốt hơn trên dữ liệu cân bằng, trong tình huống thực tế, đặc biệt là phát hiện email phishing, thuật toán phải đối mặt với điều kiện bất lợi và dữ liệu mất cân bằng. Do vậy, bản phát hành các bộ dữ liệu đã tuyển chọn [10] bao gồm cả bộ cân bằng lẫn mất cân bằng, với nhiều kích thước khác nhau, nhằm đặt ra những thách thức thực tế cho ML hoặc các phân tích tương tự để các giải pháp đích trở nên vững chắc và đáng tin cậy.

IV. Áp dụng ML lên dữ liệu đã tuyển chọn

Sau khi tạo bảy bộ dữ liệu, chúng tôi muốn xác định chúng có phù hợp để áp dụng các thuật toán ML hay không và các thuật toán ML kết hợp NLP hoạt động tốt đến mức nào khi phát hiện email phishing trên những bộ dữ liệu này.

A. Quy trình

1) Lựa chọn thuật toán ML: Để nhận diện email phishing, chúng tôi áp dụng năm thuật toán ML khác nhau: Máy véc-tơ hỗ trợ (SVM), Rừng ngẫu nhiên (RF), Extra Tree (ET), XGBoost (XGB) và AdaBoost (ADB). Chúng được chọn vì được công nhận rộng rãi và có hiệu quả trong phát hiện email phishing [20]–[23]. Thông tin chi tiết hơn về các thuật toán có thể tìm ở tài liệu khác [24].

2) Chia mẫu huấn luyện và kiểm thử: Thay vì chia huấn luyện–kiểm thử một lần đơn giản, chúng tôi sử dụng "k-fold phân tầng", là cách thực hiện kiểm định chéo 10 fold vững chắc hơn trong khi vẫn giữ tỷ lệ mẫu của từng lớp. Cách này bảo đảm các lớp khác nhau được đại diện cân đối trong cả dữ liệu huấn luyện lẫn kiểm thử, phản ánh sát phân bố trong bộ dữ liệu đầy đủ. Phương pháp đặc biệt phù hợp với dữ liệu có phân bố lớp mất cân bằng, như Ling, Assassin và TREC-06 trong các bộ dữ liệu đã tuyển chọn.

3) Các thước đo đánh giá: Với mỗi thuật toán ML áp dụng lên từng bộ dữ liệu, chúng tôi ghi nhận số dương tính đúng (TP), âm tính đúng (TN), dương tính giả (FP) và âm tính giả (FN). Trong nghiên cứu này, FN là số email phishing bị nhận diện sai thành email hợp lệ; FP là số email hợp lệ bị nhận diện sai thành phishing. Ngược lại, TP xảy ra khi thuật toán gán đúng email phishing là phishing. Tương tự, TN là trường hợp thuật toán nhận diện đúng email hợp lệ. Sau đó, chúng tôi đánh giá hiệu năng của từng thuật toán bằng các chỉ số accuracy, recall, precision, F-score và ROC [20].

4) Tính độ quan trọng của đặc trưng: Cách tính độ quan trọng trong ML phụ thuộc vào thuật toán được sử dụng. Với SVM, mỗi đặc trưng có một hệ số thể hiện trọng số của nó trong hàm quyết định. Độ quan trọng được tính bằng trị tuyệt đối của các hệ số này. Trị tuyệt đối càng lớn thì đặc trưng càng tác động mạnh đến ranh giới quyết định. Với các mô hình tổ hợp như RF và ET, độ quan trọng được tính bằng cách đo đóng góp của từng đặc trưng vào việc giảm độ hỗn tạp Gini [25] trên tất cả các cây trong rừng. Sau đó, các giá trị của từng cây được lấy trung bình để xác định độ quan trọng tổng thể. Với ADB, độ quan trọng được xác định bằng mức độ mỗi đặc trưng giúp giảm sai số dự đoán khi các bộ học yếu được kết hợp tuần tự. Với XGB, độ quan trọng được xác định bằng tổng các giá trị gain, thể hiện hiệu quả của đặc trưng trong cải thiện hiệu năng bằng cách giảm sai số. Phép tính xét tất cả những lần đặc trưng được sử dụng trên mọi cây trong tổ hợp.

Sau khi xác định độ quan trọng của từng đặc trưng trên tất cả các bộ dữ liệu, chúng tôi chuẩn hóa các giá trị về khoảng từ 0,0 đến 1,0. Điều này cho phép so sánh công bằng độ quan trọng giữa năm thuật toán ML đã chọn. Với mỗi thuật toán hoạt động trên một bộ dữ liệu cụ thể, chúng tôi xếp hạng các đặc trưng theo thứ tự giảm dần của điểm độ quan trọng đã chuẩn hóa mà thuật toán thu được trên bộ dữ liệu đó.

5) Thực thi các thuật toán ML: Để phát hiện email phishing trong từng bộ dữ liệu, chúng tôi sử dụng các đặc trưng `Subject` và `Body` đối với Ling và Enron. Với năm bộ dữ liệu còn lại, chúng tôi dùng các đặc trưng `Sender`, `Receiver`, `Date`, `Subject`, `Body` và `Urls`. Ở mỗi bộ, tập con huấn luyện được dùng để huấn luyện từng thuật toán trong năm thuật toán đã chọn, sử dụng các siêu tham số mặc định. Cuối cùng, các tập con kiểm thử được dùng để đánh giá hiệu năng. Với mỗi cặp thuật toán–bộ dữ liệu, chúng tôi tính các chỉ số đánh giá, điểm độ quan trọng chuẩn hóa và thứ hạng đặc trưng đã mô tả ở trên.

B. Phân tích và phát hiện

Đối với mỗi bộ dữ liệu đã tuyển chọn, hiệu năng của năm thuật toán ML được đo bằng accuracy, precision, recall và F-score, lấy trung bình qua 10 lần chạy tương ứng với kiểm định chéo 10 fold, được trình bày trong Bảng II. Trong bản gốc, với mỗi bộ dữ liệu, các ô tô xanh đánh dấu giá trị tốt nhất và các ô tô đỏ đánh dấu giá trị kém nhất mà năm thuật toán đạt được. Bản dịch giữ đầy đủ các giá trị dưới dạng bảng văn bản.

Bảng II. Hiệu năng các thuật toán ML trên các bộ dữ liệu đã tuyển chọn. Đơn vị của mọi giá trị là phần trăm (%).

Bộ dữ liệu	Chỉ số	SVM	RF	ET	XGB	ADB
Ling	Accuracy	84.21	97.19	97.54	98.95	98.25

Bộ dữ liệu	Chỉ số	SVM	RF	ET	XGB	ADB
Ling	Precision	70.91	97.28	97.61	98.96	98.23
Ling	Recall	84.21	97.19	97.54	98.95	98.25
Ling	F-score	76.99	97.08	97.46	98.93	98.24
Enron	Accuracy	95.87	98.69	98.69	98.45	95.70
Enron	Precision	96.09	98.69	98.69	98.46	95.72
Enron	Recall	95.87	98.69	98.69	98.45	95.70
Enron	F-score	95.87	98.69	98.69	98.45	95.70
Assassin	Accuracy	95.34	98.28	98.45	98.45	98.79
Assassin	Precision	95.52	98.28	98.45	98.45	98.79
Assassin	Recall	95.34	98.28	98.45	98.45	98.79
Assassin	F-score	95.24	98.27	98.44	98.45	98.79
TREC-05	Accuracy	97.47	98.86	99.12	98.57	95.51
TREC-05	Precision	97.47	98.86	99.12	98.57	95.51
TREC-05	Recall	97.47	98.86	99.12	98.57	95.51
TREC-05	F-score	97.47	98.86	99.12	98.57	95.51
TREC-06	Accuracy	93.48	96.34	97.01	97.99	95.43
TREC-06	Precision	93.78	96.44	97.10	97.99	95.39
TREC-06	Recall	93.48	96.34	97.01	97.99	95.43
TREC-06	F-score	93.17	96.25	96.95	97.97	95.40
TREC-07	Accuracy	99.33	99.78	99.85	99.80	98.33
TREC-07	Precision	99.33	99.78	99.85	99.80	98.36
TREC-07	Recall	99.33	99.78	99.85	99.80	98.33
TREC-07	F-score	99.33	99.78	99.85	99.80	98.33
CEAS-08	Accuracy	97.57	99.62	99.69	99.64	97.55
CEAS-08	Precision	97.58	99.62	99.69	99.64	97.61
CEAS-08	Recall	97.57	99.62	99.69	99.64	97.55
CEAS-08	F-score	97.57	99.62	99.69	99.64	97.55

1) Hiệu năng của các thuật toán ML: Như Bảng II cho thấy, với các bộ dữ liệu tương đối cân bằng Enron, TREC-07, CEAS-08 và TREC-05, ET hoạt động tốt nhất còn ADB kém nhất.

Tình hình thay đổi ở các bộ mất cân bằng mạnh là Assassin, Ling và TREC-06. Với chúng, các thuật toán boosting ADB và XGB tỏ ra vượt trội. Chiến lược tập trung dần vào những điểm dữ liệu bị phân loại sai cho phép chúng nâng cao độ chính xác đối với lớp ít được đại diện hơn. Đáng chú ý, trên các bộ dữ liệu mất cân bằng mạnh, SVM rõ ràng tụt lại so với bốn mô hình tổ hợp RF, ET, ADB và XGB. Để hiểu sâu hơn nguyên nhân cụ thể của kết quả kém này, cần tiến hành phân tích độ quan trọng của đặc trưng. Những hiểu biết thu được từ phân tích đặc trưng, được thảo luận ở Mục IV-B2, giúp giải thích hiệu năng kém của SVM.

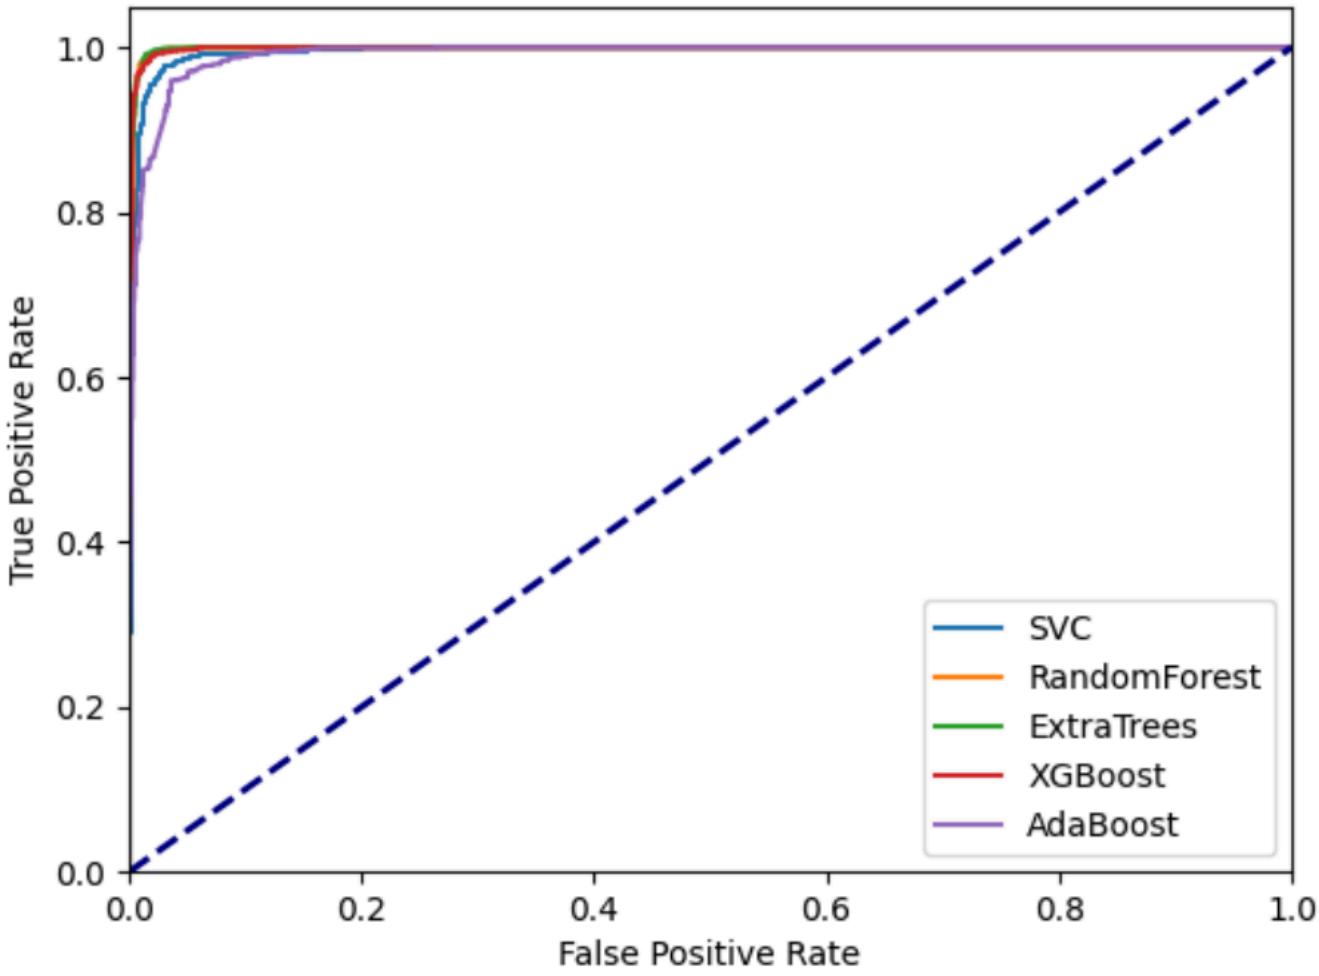
Với các bộ dữ liệu lớn, đặc biệt những bộ có gần 40 nghìn mẫu trở lên như TREC-05, TREC-07 và CEAS-08, ET liên tục vượt các thuật toán ML còn lại. Tác giả cho rằng hiệu năng này có thể bắt nguồn từ đặc tính ngẫu nhiên hóa riêng và khả năng xử lý thành thạo sự phức tạp của tương tác giữa các đặc trưng trong dữ liệu của ET. Ngược lại, trên những bộ lớn này, ADB hoạt động kém hơn các thuật toán còn lại. Tuy nhiên, ADB đạt kết quả tốt hơn khi áp dụng lên các bộ nhỏ như Ling và Assassin.

Bảng III. Các giá trị ma trận nhầm lẫn trên những bộ dữ liệu đã tuyển chọn. Cột cuối là tỷ lệ dự đoán sai (%); các số được giữ đúng như bản gốc.

Bộ dữ liệu	Thuật toán ML tốt nhất	TP	TN	FP	FN	Dự đoán sai (%)
TREC-07	ET	2.938	2.429	7	1	0.15
CEAS-08	ET	2.176	1.727	4	8	0.31
Assassin	ADB	167	809	3	4	0.71
TREC-05	ET	2.276	3.214	18	33	0.92
Ling	XGB	42	240	0	3	1.05
Enron	ET	1.377	1.560	19	20	1.31
TREC-06	XGB	374	1.234	7	26	2.01

Với mỗi bộ trong bảy bộ dữ liệu, Bảng III trình bày thuật toán ML có hiệu năng tốt nhất cùng số TP, TN, FP và FN tương ứng. Tỷ lệ dự đoán sai của thuật toán tốt nhất cũng được nêu ở cột ngoài cùng bên phải. Từ Bảng III có thể thấy tỷ lệ dự đoán sai thấp nhất thuộc về TREC-07 (0,15%) và CEAS-08 (0,31%).

Trên tất cả các bộ dữ liệu đã tuyển chọn, từng thuật toán trong năm thuật toán ML đều đạt điểm ROC cao, từ 98,55% trở lên. Chẳng hạn, Hình 2 trình bày các đường cong ROC khi áp dụng các thuật toán lên Enron, trong đó ET tốt nhất với điểm ROC 99,88%. Các đường cong ROC tương tự với điểm cao cũng được quan sát trên mọi bộ dữ liệu. Điểm ROC cao, cùng accuracy, precision, recall và F-score cao mà các thuật toán đạt được trên tất cả các bộ dữ liệu (Bảng II), theo tác giả, cho thấy các bộ dữ liệu đã được tuyển chọn tốt và cho phép ML phân loại email với hiệu năng rất tốt.



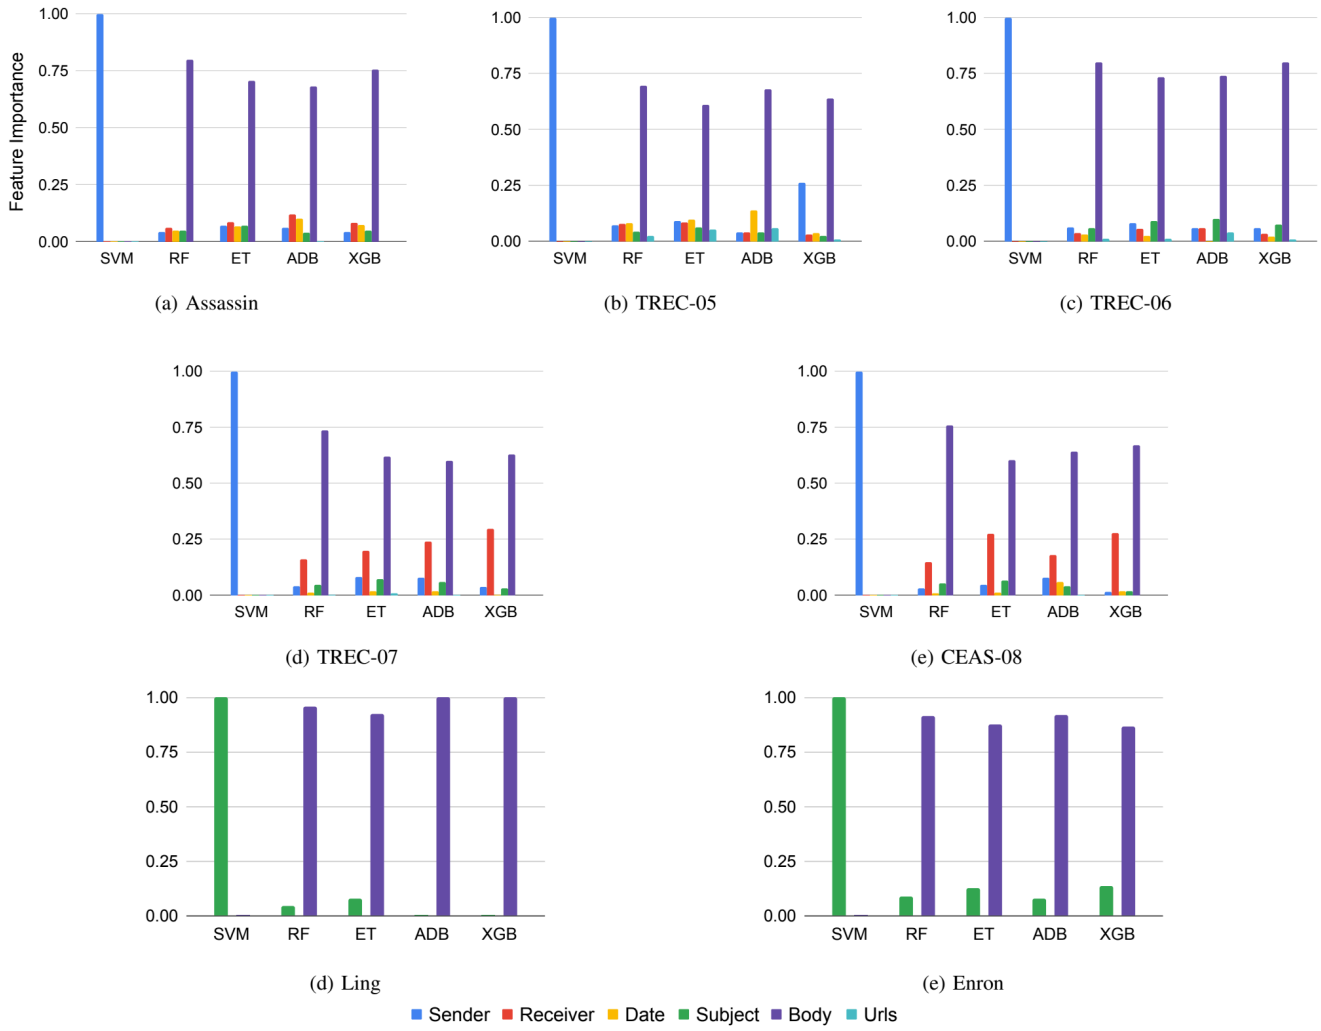
Hình 2. Đường cong ROC trên bộ dữ liệu Enron.

Dịch nhãn trong hình: Trục ngang: tỷ lệ dương tính giả (False Positive Rate); trục dọc: tỷ lệ dương tính đúng (True Positive Rate). Chú giải gồm SVC (bộ phân loại SVM), RandomForest, ExtraTrees, XGBoost và AdaBoost.

2) Phân tích độ quan trọng của đặc trưng: Như đã thảo luận ở Mục IV-B1, một số thuật toán ML hoạt động tốt hơn trên dữ liệu tương đối lớn và cân bằng, trong khi những thuật toán khác hoạt động tốt hơn trên dữ liệu nhỏ hơn và mất cân bằng. Để hiểu nguyên nhân và rút ra nhận định về độ quan trọng tương đối của các đặc trưng email, chúng tôi thực hiện phân tích đặc trưng.

Với mỗi bộ dữ liệu, Hình 3 trình bày điểm độ quan trọng chuẩn hóa của các đặc trưng đối với từng thuật toán trong năm thuật toán ML. Như hình cho thấy, trên tất cả các bộ dữ liệu, `Body` thể hiện độ quan trọng hàng đầu ở mọi thuật toán, ngoại trừ SVM. Đáng ngạc nhiên, SVM coi `Sender`, nếu có, là đặc trưng quan trọng nhất. Với hai bộ chỉ có hai đặc trưng `Subject` và `Body` là Ling và Enron, SVM coi `Subject` quan trọng hơn `Body`. Tác giả cho rằng điều này là nguyên nhân khiến SVM đạt hiệu năng thấp nhất trong năm thuật toán được sử dụng.

Như Hình 3 cho thấy, độ quan trọng của những đặc trưng khác thay đổi theo thuật toán và theo từng bộ dữ liệu. Hầu hết các thuật toán, ngoại trừ SVM, chú trọng các đặc trưng như `Sender`, `Receiver`, thậm chí `Date` trong một số trường hợp, nhiều hơn `Subject`. Ngược lại, cả năm thuật toán đều gán độ quan trọng thấp nhất cho đặc trưng có/không có `Urls`.



Hình 3. Độ quan trọng tương đối của các đặc trưng đối với năm thuật toán ML khác nhau khi chạy trên bảy bộ dữ liệu đã tuyển chọn.

Dịch nhãn trong hình: Feature Importance = độ quan trọng của đặc trưng. Sender = người gửi; Receiver = người nhận; Date = ngày; Subject = tiêu đề; Body = phần thân; Urls = các URL. Các biểu đồ con lần lượt là Assassin, TREC-05, TREC-06, TREC-07, CEAS-08, Ling và Enron; trục ngang liệt kê SVM, RF, ET, ADB, XGB. Ký hiệu các biểu đồ con bị lặp "(d)" và "(e)" ở hàng cuối được giữ nguyên từ hình gốc.

Bảng IV. Điểm độ quan trọng chuẩn hóa và thứ hạng đặc trưng. Hạng 1 là quan trọng nhất. Dấu "—" biểu thị trường không có trong bộ dữ liệu.

Bộ dữ liệu	Thuật toán tốt nhất / loại giá trị	Sender	Receiver	Date	Subject	Body	Urls
Assassin	ADB: điểm	0.06	0.12	0.10	0.04	0.68	0.00
Assassin	Hạng	4	2	3	5	1	6
TREC-05	ET: điểm	0.09	0.08	0.10	0.06	0.61	0.05
TREC-05	Hạng	3	4	2	5	1	6
TREC-06	XGB: điểm	0.06	0.03	0.02	0.08	0.80	0.01
TREC-06	Hạng	3	4	5	2	1	6

Bộ dữ liệu	Thuật toán tốt nhất / loại giá trị	Sender	Receiver	Date	Subject	Body	Urls
TREC-07	ET: điểm	0.08	0.20	0.02	0.07	0.62	0.01
TREC-07	Hạng	3	2	5	4	1	6
CEAS-08	ET: điểm	0.05	0.27	0.01	0.07	0.60	0.00
CEAS-08	Hạng	4	2	5	3	1	6
Ling	XGB: điểm	—	—	—	0.00	1.00	—
Ling	Hạng	—	—	—	2	1	—
Enron	ET: điểm	—	—	—	0.09	0.91	—
Enron	Hạng	—	—	—	2	1	—

Để hiểu sâu hơn, chúng tôi tập trung vào thuật toán hoạt động tốt nhất trên từng bộ trong bảy bộ dữ liệu, vì chúng có thể cho biết các thuật toán đã nhấn mạnh những đặc trưng nào để đạt hiệu năng tốt hơn. Với mỗi bộ dữ liệu, Bảng IV xác định thuật toán tốt nhất và trình bày điểm độ quan trọng chuẩn hóa mà thuật toán thu được cho các đặc trưng hiện có. Để thuận tiện khi diễn giải, chúng tôi cũng xếp hạng các đặc trưng cho từng cặp thuật toán–bộ dữ liệu.

Không có gì bất ngờ khi Bảng IV cho thấy trên mọi bộ dữ liệu, `Body` được xếp hạng 1, tức quan trọng nhất, ở tất cả những thuật toán đạt hiệu năng tốt nhất; trong khi `Urls` liên tục bị coi là ít quan trọng nhất với hạng 6. Điều gây ngạc nhiên là `Sender` cũng không được xem là quá quan trọng.

Từ những quan sát trên, chúng tôi nhận thấy chỉ riêng việc có hoặc không có URL không đóng góp nhiều vào khả năng phát hiện email phishing của ML. Phân tích URL tốt hơn, cung cấp chỉ dấu URL có độc hại hay không, có thể tạo ra một đặc trưng hữu ích. Hơn nữa, phân tích sâu xem địa chỉ email `Sender` có thực sự tương ứng với người gửi hợp lệ được khai nhận hay không, chẳng hạn tên người hoặc tổ chức, cũng có thể tạo ra đặc trưng có tác động mạnh để phân biệt email phishing.

V. Các yếu tố đe dọa tính hợp lệ

Cơ chế phát hiện email phishing của chúng tôi dựa trên việc đánh giá bảy bộ dữ liệu đã tuyển chọn do chúng tôi tạo ra. Các bộ dữ liệu chỉ gồm email viết bằng tiếng Anh. Vì vậy, khả năng áp dụng rộng rãi các phát hiện có thể bị hạn chế bởi lựa chọn ngôn ngữ này. Khảo sát dữ liệu đa ngôn ngữ có thể mang lại thêm hiểu biết và những thách thức mới trong phát hiện email phishing.

Trong công trình này, chúng tôi chỉ xét sự hiện diện của URL trong phần thân email. Tuy nhiên, phân tích toàn diện các liên kết URL đầy đủ, nghiên cứu cấu trúc, tên miền và những thuộc tính khác của chúng có thể phát hiện các mẫu và dấu hiệu phishing tinh vi hơn. Tệp đính kèm email không được xem xét trong công trình này. Chúng tôi dự định giải quyết giới hạn đó trong nghiên cứu tiếp theo.

Trên các bộ dữ liệu đã tuyển chọn, chúng tôi chỉ áp dụng năm thuật toán ML phổ biến và không thuật toán nào sử dụng học sâu. Có thể coi đây là một giới hạn của công trình. Tuy nhiên, không dùng học sâu, chúng tôi vẫn đạt accuracy từ 98% trở lên trên tất cả các bộ dữ liệu. Hơn nữa, mục tiêu của công trình là tạo các bộ dữ liệu đã tuyển chọn và xác định những đặc trưng tác động mạnh nhất đến các thuật toán ML. Dù vậy, chúng tôi vẫn dự định khảo sát các thuật toán học sâu cho mục đích này trong tương lai.

VI. Công trình liên quan

Các phương pháp ML và NLP đã được dùng trong nhiều lĩnh vực [26]–[32], bao gồm nhiều khía cạnh an ninh của ứng dụng phần mềm [33]–[36]. Tương tự, những nỗ lực gần đây nhằm nhận diện email phishing cũng sử dụng ML và NLP [6], [8], [22], [37]. Một số nghiên cứu tập trung vào một thuật toán duy nhất [5], [6], [38], trong khi các nghiên cứu khác đánh giá nhiều thuật toán để tìm ra thuật toán tốt nhất [22], [23]. Có các nghiên cứu dùng một bộ dữ liệu riêng lẻ [39], nhiều bộ dữ liệu [6], [20], [22], hoặc thậm chí kết hợp nhiều bộ dữ liệu [22]. Một số xem xét phân tích đặc trưng [7], [8], trong khi các công trình khác phân tích nội dung email [40]–[42].

Một số sáng kiến gần đây nhằm cải thiện phát hiện email phishing đã kết hợp việc khơi gợi sự nghi ngờ [43] và khảo sát thủ đoạn, ý định tấn công [42]. Das và cộng sự [9] khảo sát những sắc thái của phishing và spear phishing thông qua các thách thức an ninh đặc thù. Họ nhấn mạnh nhu cầu về các bộ dữ liệu phong phú đã được tuyển chọn; công trình của chúng tôi đã tạo và công bố bảy bộ như vậy. Ngoài ra, công trình còn có phân tích đặc trưng sau khi áp dụng năm thuật toán ML lên các bộ dữ liệu đã tuyển chọn.

Một số nghiên cứu [7], [8] nhấn mạnh các đặc trưng của bộ dữ liệu, trong khi các công trình khác tập trung vào email ở những ngôn ngữ khác, chẳng hạn tiếng Ả Rập [21], [37]. Trong bối cảnh phishing điển hình, số lượng email phishing và email hợp lệ chênh lệch đáng kể. Tỷ lệ 1:1 không còn là lựa chọn phổ biến của nhiều nhà nghiên cứu [44]. Trong công trình này, chúng tôi đo hiệu quả của năm thuật toán ML trên cả dữ liệu cân bằng và mất cân bằng.

Các kỹ thuật ML như Naive Bayes, SVM, RF, Cây quyết định, Hồi quy logistic, AdaBoost, XGBoost và K láng giềng gần nhất được sử dụng rộng rãi cho phát hiện phishing [23], [38], [45]. Agarwal và Kumar [39] kết hợp Naive Bayes với Tối ưu hóa bầy đàn hạt và chỉ chạy trên một bộ dữ liệu. Islam và cộng sự [22] đánh giá bốn thuật toán ML, chú trọng các đặc trưng cụ thể của từng thuật toán. Rabbi và cộng sự [20] áp dụng sáu thuật toán ML nhưng chỉ trên hai bộ dữ liệu. Ngược lại, chúng tôi chạy năm thuật toán ML phổ biến trên bảy bộ dữ liệu đã tuyển chọn do chính chúng tôi tạo ra. Rabbi và cộng sự [20] báo cáo rằng đặc trưng `Subject` là chìa khóa cho phân loại, trong khi những phát hiện của chúng tôi dựa trên các bộ dữ liệu lớn hơn cho kết quả khác.

VII. Kết luận

Trong công trình này, trước tiên chúng tôi tạo ra bảy bộ dữ liệu đã tuyển chọn bằng cách xử lý các kho email từ nhiều nguồn khác nhau. Các bộ dữ liệu chứa 203.176 email đã tuyển chọn thuộc giai đoạn từ năm 2000 đến năm 2008, bao gồm giao tiếp email cá nhân đến nghề nghiệp, trải rộng nhiều chủ đề. Chúng tôi đã phát hành các bộ dữ liệu này để công chúng sử dụng miễn phí [10]; dữ liệu đã được chuẩn bị và sẵn sàng cho các thuật toán ML hoặc những phân tích tương tự. Bản phát hành gồm cả dữ liệu cân bằng lẫn mất cân bằng, với nhiều kích thước, nhằm đặt ra các mức độ thách thức khác nhau cho thuật toán ML.

Chúng tôi chứng minh mức độ phù hợp và sẵn sàng của dữ liệu bằng cách áp dụng năm thuật toán ML và đạt accuracy cao trong phát hiện email phishing. Chúng tôi cũng khảo sát định lượng ý nghĩa của những đặc trưng email khác nhau trong quá trình ra quyết định của thuật toán, từ đó rút ra hiểu biết về lý do một số thuật toán hoạt động tốt hơn những thuật toán khác và những việc có thể làm trong tương lai để nâng cao hiệu quả phát hiện email phishing. Phân tích định lượng cho thấy một số thuật toán, chẳng hạn SVM, nhấn mạnh các

đặc trưng không phù hợp, dẫn đến hiệu năng thấp. Chúng tôi cũng phát hiện những đặc trưng như URL và thông tin người gửi chưa được khai thác đầy đủ trong các phương pháp hiện tại.

Chúng tôi dự định giải quyết các vấn đề này bằng cách kết hợp phân tích URL để chỉ ra URL có độc hại hay không và phân tích người gửi để chỉ ra địa chỉ email có thực sự thuộc về cá nhân hoặc tổ chức được khai nhận hay không. Chúng tôi dự định tiến hành phân tích định tính các email bị phân loại sai nhằm tìm ra những mẫu khiến ML bỏ sót email phishing. Ngoài ra, chúng tôi sẽ tiếp tục mở rộng dữ liệu đã tuyển chọn và đánh giá tính hữu ích của chúng bằng các thuật toán học sâu.

Ghi chú biên dịch để đối chiếu

- Bảng I ghi tổng số của bảy bộ lần lượt là 2.859, 29.767, 5.809, 55.414, 16.416, 53.757 và 39.154; tổng các giá trị này là **203.176**, đúng với con số trong tóm tắt. Tuy nhiên, riêng TREC-05 có 32.329 email hợp lệ và 23.085 email scam, cộng lại bằng 55.414; chuỗi phép trừ từ 92.188 mẫu ban đầu qua 29.500 trùng lặp và 3.413 sai lệch lại cho 59.275. Các bước xử lý không được bản gốc mô tả như một phép kiểm kê hoàn toàn khép kín, nên giữ nguyên số đã in.
- Ở Bảng III, Assassin có TN = 809 và tỷ lệ dự đoán sai = 0.71%; chúng được giữ theo bản gốc dù không khớp trực tiếp với accuracy 98.79% trong Bảng II. Bài báo không nói rõ Bảng III là trung bình các fold hay giá trị ở một fold cụ thể; không nên tự diễn giải thành tổng dự đoán ngoài fold của toàn bộ dữ liệu.
- Trong phần giới thiệu, bản trích xuất có cụm “languages other than emails”; theo ngữ cảnh và Mục II-B4, bản dịch diễn đạt là “ngôn ngữ khác tiếng Anh”. Các thuật ngữ “encoded/encrypted” và “decoded/decrypted” của bản gốc được diễn đạt là “mã hóa” và “giải mã”; ví dụ được tác giả mô tả cụ thể là giải mã biểu diễn Base64 và bộ ký tự, không phải phá mã mật mã.
- Các thống kê an ninh trong phần giới thiệu là số liệu tác giả trích dẫn tại thời điểm công bố, không phải số liệu cập nhật của năm 2026. Các kết quả chuẩn xác của dự án DT124 được trình bày trong slide và demo riêng, theo dữ liệu và quy trình đã lưu của dự án.

Tài liệu tham khảo

Danh mục dưới đây giữ tên tác giả, nhan đề và thông tin xuất bản bằng tiếng Anh như bản gốc để thuận tiện tra cứu; số thứ tự [1]–[45] tương ứng với các trích dẫn trong bản dịch.

[1] M. Bach, T. Kamenjarska, and B. Žmuk, “Targets of phishing attacks: The bigger fish to fry,” Procedia Computer Science , vol. 204, pp. 448– 455, 2022.

[2] MimeCast, How to Stop Phishing Attacks (Whitepaper) . https://www.mimecast.com/resources/white-papers/how-to-stop-phishing-attacks/, Verified: Sept 2023.

[3] “The latest 2023 phishing statistics (updated august 2023),” 2023.

[4] N. James, “81 phishing attack statistics 2023: The ultimate insight,” Verified: Sept 2023.

[5] S. Dhavale, “C-asft: convolutional neural networks-based anti-spam filtering technique,” in Proceeding of ICCSA , 2020, pp. 49–55.

[6] W. Pan, J. Li, L. Gao, L. Yue, Y . Yang, L. Deng, and C. Deng, “Semantic graph neural network: a conversion from spam email classification to graph classification,” Scientific Programming, vol. 2022, pp. 1–8, 2022.

[7] M. Alam, D. Sarma, F. Lima, I. Saha, R. Ulfath, and S. Hossain, “Phishing attacks detection using machine learning approach,” in ICSSIT, 2020, pp. 1173–1179.

[8] S. Salloum, T. Gaber, S. Vadera, and K. Shaalan, “Phishing email detection using natural language processing techniques: A literature survey,” Procedia Computer Science , vol. 189, pp. 19–28, 2021.

[9] A. Das, S. Baki, A. El Aassal, R. Verma, and A. Dunbar, “Sok: a comprehensive reexamination of phishing research from the security perspective,” Commun Surv Tutor , vol. 22, no. 1, pp. 671–708, 2019.

[10] Seven Phishing Email Datasets . https://doi.org/10.6084/m9.figshare.25432108.v1, 2024.

[11] A. Champa, M. Rabbi, and M. Zibran, “Curated datasets and feature analysis for phishing email detection with machine learning,” in ICMI, 2024, pp. 1–7 (to appear).

[12] G. Sakkis, I. Androutsopoulos, G. Paliouras, V . Karkaletsis, C. D. Spyropoulos, and P. Stamatopoulos, “A memory-based approach to anti-spam filtering for mailing lists,” Information retrieval, vol. 6, pp. 49–73, 2003.

[13] B. Klimt and Y . Yang, “The enron corpus: A new dataset for email classification research,” in ECML, 2004, pp. 217–226.

[14] A. Schwartz, Apache SpamAssassin. https://spamassassin.apache.org/, Verified: August 2023.

[15] N. Craswell, A. De Vries, and I. Soboroff, “Overview of the trec 2005 enterprise track.” in TREC, vol. 5, 2005, pp. 1–7.

[16] A. Bratko, B. Filipic, and B. Zupan, “Towards practical ppm spam filtering: Experiments for the trec 2006 spam track.” in TREC, 2006.

[17] G. V . Cormack, “Trec 2007 spam track overview,” in Proc. of TREC , vol. 500, 2007, p. 274.

[18] D. DeBarr and H. Wechsler, “Spam detection using random boost,” Pattern Recognition Letters, vol. 33, no. 10, pp. 1237–1244, 2012.

[19] Python. (2023) email — an email and mime handling package. [Online]. Available: https://docs.python.org/3.8/library/email.html

[20] M. Rabbi, A. Champa, and M. Zibran, “Phishy? detecting phishing emails using ml and nlp,” in SERA, 2023, pp. 77–83.

[21] S. Salloum, T. Gaber, S. Vadera, and K. Shaalan, “A new english/arabic parallel corpus for phishing emails,” TALLIP, vol. 22, pp. 1–17, 2023.

[22] M. Islam, M. Al Amin, M. Islam, M. Mahbub, M. Showrov, and C. Kaushal, “Spam-detection with comparative analysis and spamming words extractions,” in ICRITO, 2021, pp. 1–9.

[23] Y . Murti and P. Naveen, “Machine learning algorithms for phishing email detection,” JLISS, vol. 10, no. 2, pp. 249–261, 2023.

[24] A. Géron, Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow. O’Reilly Media, Inc., 2022.

[25] Scikit-Learn. (2023) sklearn.ensemble.randomforestclassifier. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html

[26] M. F. Rabbi, A. I. Champa, M. F. Zibran, and M. R. Islam, “Ai writes, we analyze: The chatgpt python code saga,” in MSR, 2024, pp. 1–5 (to appear).

[27] A. I. Champa, M. F. Rabbi, M. F. Zibran, and M. R. Islam, “Insights into female contributions in open-source projects,” in MSR, 2023, pp. 357–361.

[28] M. Zibran, “On the effectiveness of labeled latent dirichlet allocation in automatic bug-report categorization,” in ICSE, 2016, pp. 713–715.

[29] A. I. Champa, M. F. Rabbi, and M. F. Zibran, “Chatgpt in action: Analyzing its use in software development,” in MSR, 2024, pp. 1–5 (to appear).

[30] S. M. Mahedy Hasan, M. F. Rabbi, A. I. Champa, and M. A. Zaman, “An effective diabetes prediction system using machine learning techniques,” in ICAICT, 2020, pp. 23–28.

[31] A. I. Champa, M. F. Rabbi, S. M. Mahedy Hasan, A. Zaman, and M. H. Kabir, “Tree-based classifier for hyperspectral image classification via hybrid technique of feature reduction,” inICICT4SD, 2021, pp. 115–119.

[32] M. Islam, M. Ahmmed, and M. Zibran, “Marvalous: Machine learning based detection of emotions in the valence-arousal space in software engineering text,” in ACM SAC, 2019, pp. 1786–1793.

[33] A. Rajbhandari, M. Zibran, and F. Eishita, “Security versus performance bugs: How bugs are handled in the chromium project,” in SERA, 2022, pp. 70–76.

[34] A. Champa, M. Rabbi, F. Eishita, and M. Zibran, “Are we aware? an empirical study on the privacy and security awareness of smartphone sensors,” in SERA, 2023, pp. 1–8.

[35] M. Islam, M. Zibran, and A. Nagpal, “Security vulnerabilities in categories of clones and non-cloned code: An empirical study,” inESEM, 2017, pp. 20–29.

[36] M. F. Rabbi, A. I. Champa, C. Nachuma, and M. F. Zibran, “Sbom generation tools under microscope: A focus on the npm ecosystem,” in ACM SAC, 2024, pp. 1–9 (to appear).

[37] R. Al-Yozbaky and M. Alanezi, “Detection and analyzing phishing emails using nlp techniques,” in HORA, 2023, pp. 1–6.

[38] R. Ibrahim, M. Argungu, and I. Mungadi, “Development of an ensemble classification model based on hybrid filter-wrapper feature selection for email phishing detection,” International Journal of Computer and Systems Engineering, vol. 17, no. 9, pp. 519–523, 2023.

[39] K. Agarwal and T. Kumar, “Email spam detection using integrated approach of naïve bayes and particle swarm optimization,” in ICICCS, 2018, pp. 685–690.

[40] Y . Teo, “Phishing attack detection using machine learning techniques,” Ph.D. dissertation, TAR UMT, 2023.

[41] B. Ampel, Y . Gao, J. Hu, S. Samtani, and H. Chen, “Benchmarking the robustness of phishing email detection systems,” 2023.

[42] D. Bera, O. Ogbanufe, and D. Kim, “Towards a thematic dimensional framework of online fraud: An exploration of fraudulent email attack tactics and intentions,” Decision Support Systems , p. 113977, 2023.

[43] M. Harris and D. House, “Invoking suspicion for improved accuracy in phishing email identification,” 2023.

[44] M. Zareapoor and K. Seeja, “Feature extraction or feature selection for text classification: A case study on phishing email detection,” IJIEEB, vol. 7, no. 2, p. 60, 2015.

[45] P. Dinesh, M. Mukesh, B. Navaneethan, R. Sabeenian, M. Paramasivam, and A. Manjunathan, “Identification of phishing attacks using machine learning algorithm,” in E3S Web of Conf. , vol. 399, 2023, p. 04010.